

UNIVERSIDADE DE SÃO PAULO

Instituto de Ciências Matemáticas e de Computação

SSC0964 - Introdução à Computação no Mercado Financeiro

Prof. Dr. Denis Fernando Wolf

Alocação Sistemática em Classes de Ativos por Aprendizado Supervisionado

Bruno Garcia de Oliveira Breda N° USP 11212702

Vitor Antonio de Almeida Lacerda N° USP 12544761

São Carlos - SP

1º Semestre de 2026

1. Introdução

A decisão sobre como distribuir o capital entre diferentes classes de ativos é reconhecida como o principal determinante do desempenho de uma carteira no longo prazo, respondendo por uma parcela do resultado bem maior do que a escolha de papéis individuais dentro de cada classe. Em um país como o Brasil, no qual a taxa básica de juros é historicamente elevada, essa decisão ganha um contorno ainda mais delicado, pois o custo de oportunidade de qualquer aplicação é o próprio CDI, que entrega retornos altos com risco praticamente nulo. Alocar de forma sistemática significa, portanto, definir regras objetivas e replicáveis que indiquem, a cada período, quanto destinar a ações, renda fixa, ouro, moeda estrangeira ou caixa, sem depender de opiniões pontuais ou da intuição do gestor.

As abordagens clássicas para esse problema vão da otimização de média e variância proposta por Markowitz até as regras técnicas aplicadas a uma única série de preços, como o cruzamento de médias móveis e as Bandas de Bollinger, estudadas em aula. Tais regras costumam observar apenas o histórico de preços de um ativo isolado e tomar decisões binárias de compra e venda. Foi adotada neste trabalho uma estratégia diferente, que trata a alocação como um problema de aprendizado supervisionado e que combina, num mesmo modelo, informações de diversas classes de ativos com variáveis macroeconômicas do ambiente brasileiro.

A originalidade da proposta está em dois pontos centrais. O primeiro é a variável de saída do modelo. Em vez de tentar prever se o preço de um ativo vai subir ou cair, o que é notoriamente difícil e instável, foi definido um alvo mais útil para a decisão de alocação, que é a probabilidade de cada classe de ativo superar o CDI no mês seguinte. Essa probabilidade é interpretada como um grau de convicção e usada diretamente para dimensionar o tamanho de cada posição. O segundo ponto é a escolha das variáveis de entrada, que reúnem sinais técnicos calculados para cada ativo, como momentum, volatilidade e distância da média, com um conjunto de indicadores macroeconômicos compartilhados, como o juro real, a variação recente da Selic, o ritmo da inflação medida pelo IPCA e pelo IGP-M, a inclinação implícita da curva de juros e a tendência do dólar e das bolsas internacionais.

O objetivo do trabalho foi construir e avaliar, de ponta a ponta, um sistema de alocação que aprende com o histórico a reconhecer em quais regimes cada classe de ativo tende a remunerar acima do caixa, e que converte esse conhecimento em uma carteira diversificada e com risco controlado. Foram comparados quatro algoritmos de aprendizado supervisionado vistos na disciplina, a saber, regressão logística, floresta aleatória, gradient boosting e rede neural do tipo perceptron multicamadas, todos avaliados de maneira honesta fora da amostra, sobre dados mensais que cobrem de dezembro de 1999 a maio de 2026.

2. Metodologia

2.1. Base de dados e universo de ativos

Foi utilizada a base de índices fornecida na disciplina, com observações mensais que se estendem de dezembro de 1999 a maio de 2026, totalizando 318 meses sem dados faltantes. A partir dos níveis de cada índice foram calculados os retornos mensais simples, que constituem a matéria-prima de todas as etapas seguintes. O universo de decisão foi composto por oito classes de ativos investíveis, e a taxa Selic acumulada foi adotada como representação do caixa, ou seja, do ativo livre de risco contra o qual todas as demais classes são comparadas. Além das séries investíveis, um grupo de variáveis macroeconômicas foi reservado exclusivamente para a geração de atributos, sem nunca compor a carteira. A Tabela 1 resume essa organização.

Tabela 1 - Universo de ativos e variáveis utilizadas. Fonte: Elaborado pelos autores.

Papel na estratégia	Séries	Descrição
Ações Brasil	IBOV, IDIV, UTIL, IFNC	Índice amplo e setores de dividendos, utilidades e financeiro
Ações exterior	SP500BR	S&P 500 convertido para reais, que embute o câmbio
Proteção	OURO	Ouro, ativo descorrelacionado e defensivo
Renda fixa	IMAB, IMAB5	Títulos públicos atrelados à inflação, duration longa e curta
Caixa (livre de risco)	SELIC-ACC	Selic acumulada, usada como referência e como posição de proteção
Macro (apenas atributos)	USD, IPCA, IGP-M, SELIC-META, SP500USD	Câmbio, inflação, juro de política e bolsa global

A inclusão dos setores de ações brasileiras, e não apenas do índice amplo, foi uma decisão deliberada. Ela amplia o número de apostas independentes que a estratégia pode realizar a cada mês, o que se conecta diretamente à Lei Fundamental da Gestão Ativa apresentada em aula, segundo a qual o desempenho de um gestor cresce com a sua capacidade de previsão e com a raiz quadrada do número de oportunidades distintas que ele explora.

2.2. Definição do problema e variável-alvo

O problema foi formulado como uma classificação binária aplicada a cada par formado por um mês e uma classe de ativo. Para cada par, o rótulo recebe o valor um quando o retorno do ativo no mês seguinte supera o retorno do caixa no mesmo mês, e recebe o valor zero caso contrário. Em outras palavras, o modelo não responde se o ativo vai subir, e sim se vale a pena estar nele em vez de permanecer no CDI. Essa formulação é mais aderente à decisão de alocação e tende a ser mais estável do que a previsão direta de retornos, que é fortemente contaminada por ruído.

Um cuidado essencial foi o tratamento do tempo, de modo a impedir qualquer uso indevido de informação futura. Os atributos de um determinado mês são construídos apenas com dados disponíveis até o fechamento daquele mês, ao passo que o rótulo observa o desempenho que se realiza somente no mês seguinte. Assim, a previsão é genuinamente feita um passo à frente, replicando a situação de um gestor que decide hoje sem conhecer o amanhã.

2.3. Engenharia de atributos

O conjunto de atributos foi projetado para combinar duas fontes de informação complementares. A primeira é técnica e específica de cada ativo, capturando o comportamento recente da própria série. A segunda é macroeconômica e compartilhada por todos os ativos em um mesmo mês, descrevendo o regime de mercado no qual a decisão é tomada. Foi essa fusão, somada à identidade de cada classe representada por variáveis indicadoras, que produziu um total de 34 atributos por observação. A Tabela 2 organiza esses atributos em grupos e explica a intuição por trás de cada um.

Tabela 2 - Grupos de atributos de entrada do modelo. Fonte: Elaborado pelos autores.

Grupo	Atributos	Intuição
Momentum	Retornos de 1, 3, 6 e 12 meses	Captura a continuidade de tendências, um efeito amplamente documentado
Momentum em excesso	Retornos acima do caixa em 1, 3, 6 e 12 meses	Mede a tendência líquida do custo de oportunidade
Volatilidade	Desvio padrão dos retornos em 3, 6 e 12 meses	Indica o regime de risco e alimenta a gestão de risco
Reversão à média	Distância padronizada da média móvel de 6 e 12 meses	Versão estatística da ideia das Bandas de Bollinger
Aceleração	Variação do momentum de 3 meses	Detecta perda ou ganho de força do movimento
Macro de juros	Juro real, Selic meta, variação da Selic em 3 meses	Resume o regime monetário, que move renda fixa e ações
Macro de inflação	IPCA e IGP-M em 12 meses	Ambiente inflacionário, relevante para títulos atrelados ao IPCA
Curva e câmbio	Inclinação IMA-B menos IMA-B 5, tendência do dólar em 1, 3 e 6 meses	Aversão a risco e expectativas de juros longos
Bolsa global	Tendência do S&P 500 em dólar em 3 e 6 meses	Beta global e apetite internacional por risco
Identidade do ativo	Variáveis indicadoras por classe	Permite ao modelo aprender prêmios de risco distintos

Vale destacar que o atributo de distância da média foi calculado como um escore padronizado, ou seja, a diferença entre o preço e a sua média móvel dividida pelo desvio padrão do período. Essa transformação cumpre o mesmo papel das Bandas de Bollinger discutidas em aula, porém de forma contínua e comparável entre ativos de escalas diferentes, o que é mais adequado para um modelo estatístico.

2.4. Modelos de aprendizado supervisionado

Foram treinados e comparados quatro algoritmos de classificação, todos apresentados na aula de Aprendizado de Máquina. A regressão logística serviu como referência linear e interpretável. A floresta aleatória e o gradient boosting representam os métodos baseados em conjuntos de árvores de decisão, que combinam muitas árvores simples para obter

robustez e capacidade de capturar relações não lineares. A rede neural do tipo perceptron multicamadas representa a abordagem conexionista. Foi avaliado ainda um comitê, formado pela média das probabilidades dos três modelos de aprendizado de máquina, com o intuito de verificar se a combinação traria ganho de estabilidade.

Para reduzir o risco de superajuste, que foi enfatizado em aula como uma das principais armadilhas do aprendizado de máquina, os hiperparâmetros foram mantidos conservadores. As árvores tiveram profundidade limitada e um número mínimo de amostras por folha relativamente alto, a rede neural recebeu regularização e parada antecipada, e as variáveis foram padronizadas antes de alimentar os modelos sensíveis à escala. O objetivo foi privilegiar a capacidade de generalização em vez do ajuste perfeito ao passado.

2.5. Validação walk-forward

A avaliação foi conduzida por um procedimento de validação com janela expansível, conhecido como walk-forward. A cada mês de decisão, o modelo é treinado exclusivamente com observações cujo resultado já se realizou, e em seguida gera as probabilidades para o mês corrente. No mês seguinte, a janela de treino é ampliada para incorporar o novo dado observado, e o processo se repete. Foi exigido um histórico mínimo de cinco anos antes da primeira previsão, de modo que o período efetivamente avaliado fora da amostra vai de janeiro de 2005 a maio de 2026, o que corresponde a 258 meses de decisões independentes.

A qualidade preditiva foi medida pela acurácia, pela área sob a curva ROC e pelo coeficiente de informação, definido como a correlação entre a probabilidade prevista e o excesso de retorno efetivamente realizado em relação ao caixa. Esse último indicador é particularmente informativo, pois mede se a convicção do modelo de fato se traduz em retorno.

2.6. Estratégia de alocação e gestão de risco

As probabilidades previstas foram convertidas em pesos de carteira por meio de uma regra que une convicção e controle de risco. Para cada ativo, a convicção foi definida como o quanto a probabilidade prevista excede o limiar de cinquenta por cento, de forma que apenas ativos considerados atraentes recebem alocação. Essa convicção foi então ponderada pelo inverso da volatilidade recente do ativo, o que faz com que classes mais arriscadas entrem com peso menor para uma mesma convicção. Os pesos resultantes foram normalizados, limitados a um teto de trinta e cinco por cento por ativo para garantir diversificação, e a fração não alocada foi direcionada ao caixa remunerado pela Selic.

Essa construção reúne os três princípios de gestão de risco discutidos em aula. A ponderação pelo inverso da volatilidade é uma forma de orçamento de risco, na qual cada posição contribui de maneira mais equilibrada para o risco total. O teto por ativo funciona

como um limite de exposição por posição. E o uso do caixa como destino padrão atua como um mecanismo de proteção de capital, já que a estratégia recolhe naturalmente aos títulos públicos pós-fixados sempre que o modelo não identifica oportunidades convincentes.

2.7. Custos de transação e benchmarks

Para aproximar o resultado de condições reais, foi aplicado um custo de transação de dez centésimos por cento sobre o giro mensal da carteira, calculado como a soma das variações absolutas dos pesos entre dois meses consecutivos. Esse custo procura refletir corretagem, impostos e escorregamento de preço, conforme o modelo de custos apresentado na disciplina. O desempenho da estratégia foi comparado a quatro referências, a saber, o Ibovespa comprado e mantido, uma carteira de pesos iguais entre todos os ativos investíveis, a aplicação integral no CDI e a clássica carteira sessenta por cento em ações e quarenta por cento em renda fixa. As métricas de avaliação incluíram o retorno anualizado, a volatilidade anualizada, o índice de Sharpe calculado sobre o excesso em relação ao CDI, o drawdown máximo, a taxa de acerto mensal e o payoff, este último na forma da razão entre o ganho médio e a perda média.

3. Resultados e Discussões

3.1. Qualidade preditiva dos modelos

A Tabela 3 apresenta as métricas de previsão fora da amostra para os quatro algoritmos e para o comitê. O primeiro ponto que merece atenção é a taxa de base, que indica que, no período avaliado, as classes de ativos superaram o caixa em apenas cerca de cinquenta e três por cento dos meses. Esse número confirma que bater o CDI no Brasil é uma tarefa difícil e estabelece um patamar exigente para qualquer modelo.

Tabela 3 - Qualidade preditiva fora da amostra, janeiro de 2005 a maio de 2026. Fonte: Elaborado pelos autores.

Modelo	Acurácia	AUC	Coef. de informação
Floresta aleatória	0,543	0,552	0,052
Gradient boosting	0,534	0,548	0,058
Comitê (média)	0,538	0,548	0,053
Regressão logística	0,513	0,524	0,054
Rede neural (MLP)	0,521	0,514	0,016

Todos os modelos baseados em árvores superaram a taxa de base, com destaque para a floresta aleatória, que atingiu acurácia de aproximadamente cinquenta e quatro por cento e a maior área sob a curva ROC. Os coeficientes de informação positivos, na casa de cinco a seis centésimos, indicam que a convicção dos modelos guarda relação real com o retorno futuro. Embora esses valores possam parecer modestos, eles estão em linha com o que se observa na prática de mercado, e cabe lembrar a comparação feita em aula, na qual foi mencionado que o renomado fundo Medallion apresentou taxa de acerto próxima de cinquenta e um por cento. O que torna uma vantagem pequena lucrativa é a sua aplicação consistente sobre muitas apostas independentes, exatamente o que a estratégia faz ao decidir mês a mês sobre oito classes simultaneamente. A rede neural foi o modelo mais fraco, com coeficiente de informação próximo de zero, o que sugere maior dificuldade de generalização nesse conjunto de dados.

3.2. Desempenho da carteira

Traduzida a previsão em alocação, a floresta aleatória foi a estratégia de melhor desempenho ajustado ao risco, e seus principais números estão sintetizados a seguir. O resultado é expressivo, pois combina um retorno anualizado superior ao do Ibovespa com uma volatilidade muito menor e um drawdown máximo notavelmente contido.



A Tabela 4 posiciona todas as estratégias frente aos benchmarks. A leitura conjunta revela um padrão claro. As estratégias baseadas em aprendizado supervisionado entregaram retornos próximos ou superiores ao do Ibovespa, mas com uma fração da sua volatilidade e, sobretudo, com drawdowns muito menores. A floresta aleatória se destacou por unir o melhor índice de Sharpe, igual a 0,43, ao menor drawdown máximo entre todas as carteiras, de apenas sete vírgula sete por cento negativos, contra quase cinquenta por cento negativos do Ibovespa no mesmo período.


Tabela 4 - Desempenho das estratégias e dos benchmarks, janeiro de 2005 a maio de 2026, líquido de custos. Fonte: Elaborado pelos autores.

Carteira	Ret. a.a.	Vol. a.a.	Sharpe	Drawdown	Taxa acerto	Ret. acum.
Floresta aleatória	13,8%	7,0%	0,43	-7,7%	80,5%	1.497,8%
Rede neural (MLP)	13,9%	9,3%	0,36	-20,0%	70,8%	1.528,1%
Regressão logística	13,0%	8,3%	0,29	-10,8%	75,1%	1.261,5%
Gradient boosting	12,6%	7,9%	0,25	-27,0%	79,0%	1.167,5%
Comitê (média)	12,7%	8,7%	0,25	-29,8%	77,8%	1.187,3%
Carteira de pesos iguais	14,3%	10,8%	0,36	-21,9%	65,8%	1.657,5%
CDI (caixa)	10,7%	1,0%	—	0,0%	100%	779,3%
Carteira 60/40	11,0%	14,8%	0,09	-33,3%	58,8%	831,9%
Ibovespa	9,3%	22,1%	0,06	-49,6%	57,2%	576,8%

A carteira de pesos iguais alcançou retorno anualizado um pouco maior, de quatorze vírgula três por cento, mas o fez assumindo volatilidade e drawdown bem mais altos, o que se reflete em um índice de Sharpe inferior ao da floresta aleatória. Isso evidencia que o ganho do modelo não está apenas em obter retorno, e sim em obter retorno com risco controlado. A taxa de acerto mensal elevada, de oitenta vírgula cinco por cento, é coerente com o comportamento esperado de uma estratégia que recolhe ao caixa em momentos de incerteza, perfil que a aula associa aos sistemas de reversão à média, marcados por acertos frequentes de pequena magnitude.


A Figura 1 mostra a evolução do patrimônio em escala logarítmica. A linha da estratégia cresce de forma consistente e com poucas interrupções, acompanhando de perto a carteira de pesos iguais, porém com trajetória visivelmente mais suave, e mantendo-se sempre acima do CDI e do Ibovespa ao longo de quase todo o período.

Figura 1 - Curva de patrimônio em escala logarítmica da estratégia frente aos benchmarks, base igual a um. Fonte: Elaborado pelos autores.



A vantagem mais marcante da estratégia aparece na Figura 2, que compara o drawdown ao longo do tempo. Enquanto o Ibovespa sofreu quedas profundas, chegando a cerca de cinquenta por cento negativos na crise de 2008, a quarenta e quatro por cento negativos em 2015 e a trinta e sete por cento negativos no choque de 2020, a estratégia raramente ultrapassou oito por cento negativos. Essa diferença é decisiva para um investidor real, pois quedas dessa magnitude no benchmark exigem anos de recuperação e costumam levar à desistência no pior momento.


Figura 2 - Drawdown da estratégia comparado ao Ibovespa e ao CDI ao longo do período avaliado. Fonte: Elaborado pelos autores.



3.3. Comportamento da alocação ao longo do tempo

A Figura 3 ilustra como a carteira se reorganiza mês a mês. Observa-se uma rotação clara entre as classes de ativos conforme o regime de mercado muda, e nota-se que a posição em caixa cresce de forma expressiva em períodos de maior estresse, quando poucas classes apresentam probabilidade de superar a Selic. Esse comportamento dinâmico, no qual a própria ausência de alocação é uma decisão ativa, é justamente o que explica os drawdowns reduzidos observados na figura anterior.


Figura 3 - Composição da carteira ao longo do tempo, com a parcela em caixa destacada. Fonte: Elaborado pelos autores.



3.4. Importância dos atributos

A Figura 4 apresenta a importância relativa dos atributos segundo a floresta aleatória. O resultado é revelador e reforça a aposta de originalidade do trabalho. Os atributos mais determinantes não foram os sinais técnicos tradicionais, e sim as variáveis macroeconômicas. A tendência do dólar em diferentes horizontes, a variação recente da Selic, o ritmo da inflação medido pelo IPCA e pelo IGP-M, o juro real e a tendência da bolsa global despontaram como os fatores mais influentes na decisão de superar ou não o caixa.

Figura 4 - Importância dos atributos estimada pela floresta aleatória ajustada ao histórico completo.
Fonte: Elaborado pelos autores.



Essa constatação faz sentido econômico. Em uma economia sensível a juros e câmbio como a brasileira, o regime macroeconômico condiciona fortemente qual classe de ativo remunera melhor em cada momento. Quando o juro real está alto, por exemplo, torna-se mais difícil para ativos de risco superarem o caixa, e o modelo aprende a reconhecer essas situações. O fato de o modelo ter atribuído mais peso ao contexto macro do que aos indicadores técnicos de cada série confirma que a combinação de dados proposta agregou informação genuína, e não apenas repetiu os sinais já explorados pelas regras técnicas vistas em aula.

4. Conclusão

Foi desenvolvida uma estratégia de alocação sistemática entre classes de ativos fundamentada em aprendizado supervisionado, na qual o modelo estima, a cada mês e para cada classe, a probabilidade de superar o CDI, e essa probabilidade é convertida em peso de carteira por meio de uma regra de gestão de risco que combina convicção, orçamento por volatilidade, limite de exposição e proteção em caixa. A proposta se diferencia das regras

técnicas de série única estudadas na disciplina tanto pela escolha original da variável de saída quanto pela combinação de sinais técnicos com um amplo conjunto de indicadores macroeconômicos na entrada.

Os resultados fora da amostra, obtidos por validação walk-forward ao longo de mais de vinte anos, mostraram que a estratégia atingiu seu objetivo. A versão baseada em floresta aleatória entregou retorno anualizado de treze vírgula oito por cento, superior ao do Ibovespa, com volatilidade de apenas sete por cento e drawdown máximo de sete vírgula sete por cento negativos, o que representa um perfil de risco muito mais favorável do que o de qualquer dos benchmarks. Em termos simples, foi obtido um retorno comparável ao das ações com um risco semelhante ao da renda fixa, e o melhor índice de Sharpe de todas as carteiras analisadas.

A análise da importância dos atributos trouxe a conclusão mais interessante do trabalho. Foi o contexto macroeconômico, e não os indicadores técnicos isolados, que mais contribuiu para as decisões do modelo, o que está alinhado à realidade de uma economia sensível a juros e câmbio. Esse achado valida a hipótese central de que combinar diferentes naturezas de dados, técnicos e macroeconômicos, sobre várias classes de ativos ao mesmo tempo, gera uma vantagem informacional que se traduz em desempenho superior e mais estável.

Cabe registrar algumas limitações que delimitam o alcance das conclusões. O Ibovespa é um índice de preço, ao passo que parte das demais séries incorpora retorno total, o que introduz uma assimetria nas comparações entre classes. O custo de transação adotado é uma aproximação razoável, porém o impacto de mercado real depende do volume efetivamente negociado. Por fim, todo backtest reflete o passado, e desempenho histórico não constitui garantia de resultado futuro. Ainda assim, o trabalho evidencia que o aprendizado supervisionado, quando aplicado com disciplina metodológica e validação honesta, é uma ferramenta poderosa para a alocação sistemática entre classes de ativos, sobretudo no contexto brasileiro.

Referências

BREIMAN, L. Random Forests. *Machine Learning*, v. 45, p. 5 a 32, 2001.

FAMA, E. F.; FRENCH, K. R. Common risk factors in the returns on stocks and bonds. *Journal of Financial Economics*, v. 33, 1993.

GRINOLD, R. C. The fundamental law of active management. *The Journal of Portfolio Management*, 1989.

KELLY, J. L. A new interpretation of information rate. *Bell System Technical Journal*, 1956.

MARKOWITZ, H. Portfolio selection. *The Journal of Finance*, v. 7, 1952.

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, v. 12, 2011.

WOLF, D. F. Notas de aula da disciplina SSC0964, Introdução à Computação no Mercado Financeiro. ICMC USP, 2026.